

日期:2026/3/31 講者:許哲豪

題目:如何打造台版 Edge Impulse TinyML 開發平台

邊緣智慧 vs. 生成智慧



邊緣智慧 Edge AI

- 強調極小化
- 裝置資源有限，例如 Flash、RAM、運算能力
- 常用在聲音、影像、運動感測
- 需要超小模型、低功耗、即時反應

生成智慧 Generative AI

- 強調極大化
- 依賴雲端大量資源
- 可處理對話、影像、程式生成
- 需要大型資料集與大型模型

AI 發展趨勢



資料來源：<https://omnixri.blogspot.com/2025/03/20250327.html>

2026/03/31

虎尾科大電機資訊學院_邱阿打講台Edge Impulse TinyML 開發平台 Part 2_OmnixRI_JackHsu

6

- AI 核心技術
- 半導體技術
- 計算能力
- 開發工具
- 基礎模型
- 多模態技術

AI 發展方向：

- 感知 AI
- 生成 AI
- 代理 AI
- 物理 AI


AI 能力提升來自：

- 預訓練尺度
- 後訓練尺度
- 測試時尺度，也就是模型推論時能進行更長思考

發展關鍵技術：

- AI 核心技術
- 半導體技術
- 計算能力
- 開發工具
- 基礎模型
- 多模態技術

AI (神經網路) 技術演進



CNN

- 主要用於影像處理
- 例如圖片分類、物件辨識

RNN

- 主要用於時序資料
- 例如語音、文字序列、感測器時間資料

Transformer

- 現在主流 AI 架構
- 支撐 LLM、VLM、VLA 等模型

LLM

- 大語言模型
- 主要處理文字

VLM

- 視覺語言模型
- 可處理圖片加文字

VLA

視覺語言動作模型，可加入控制與動作，適合機器人應用

從單一功能走向多任務協作

Edge AI 如何定義？



廣義定義：

不上網就能完成所有AI推論



狹義定義：

使用電池供電完成所有AI推論
的獨立裝置 (Endpoint Device)



只要 AI 推論不需要上網，在本地端就能完成，都可以算 Edge AI。
狹義來說，Edge AI 是使用電池供電的獨立裝置，也就是 Endpoint Device，在低功耗環境下完成 AI 推論。


這裡的核心概念是「不上雲端、直接在裝置端判斷」。優點是反應速度快、隱私性高、網路依賴低，適合穿戴裝置、感測器、智慧家電與工業監測。

Edge AI 開發流程



資料前處理：資料格式轉換、資料降維處理 (如DSP、通道合併等)

結果後處理：影像加上訊息 (文字、點線、著色等)



流程從資料收集開始，接著進行資料標註，再建立模型、訓練調參、模型優化，最後進行部署與測試。

資料前處理很重要，可能包含格式轉換、降維、濾波、DSP 特徵萃取或資料合併。

結果後處理則是把模型輸出轉成使用者看得懂的資訊，例如加上文字、畫框、點線或顏色標示。

MCU 等級主要核心晶片分類




硬體加速方式 (算力來源)

- 提高工作時脈速度
- 平行 / 向量指令集
- 多核(同質、大小核、異質) 加速

MCU

- 單核心型
- 多核心型
- 混合核心型



RISC-V 是開源指令集架構，常見廠商包括 Andes、Renesas、Kendryte、ESP32-Cx。

DSP 適合數位訊號處理，例如音訊、濾波、感測訊號運算；NPU 則是專門加速 AI 推論的處理單元。

硬體加速方式與限制

矩陣計算核心 $Y = AX + B$



1. CPU 加速工作時脈
2. 單指令週期硬體乘法、除法、浮點數計算
3. 使用 DSP 指令 (乘法累加MAC)
4. 平行 / 向量指令集 (SIMD, MVE, NEON)
5. 多核心加速 (同質、大小核)
6. GPU 加速器 (CUDA, Tensor, NVDLA)
7. DSP / NPU / FPGA 加速器
8. 專用晶片 ASIC

硬體加速阻礙

算力牆

記憶體牆

能耗牆

通訊牆

矩陣運算是 AI 模型的核心，例如 $Y = AX + B$ ，因此加速矩陣乘法能明顯提升推論速度。常見加速方式包含提高 CPU 時脈、使用硬體乘法器、使用 DSP 指令、SIMD 向量指令、多核心加速、GPU、DSP、NPU、FPGA 或 ASIC。

但硬體加速也會遇到限制，例如算力牆、記憶體牆、功耗牆與通訊牆。意思是即使晶片算得快，也可能卡在資料搬移、記憶體頻寬、耗電量或通訊速度。

主流 AI 開發工具

伺服器、桌機、筆電
(Windows, Linux, MacOS)

手機、平板、單板微電腦
(Android, iOS)

微控制器、單晶片
(裸機, freeRTOS, zephyr)


TensorFlow

 TensorFlow Lite
(現名 LiteRT) 

 TensorFlow Lite
(for microcontroller)

 PyTorch

 PyTorch
(for mobile) 

 ExecuTorch

在伺服器、桌機與筆電上，常見工具有 TensorFlow 與 PyTorch，適合模型訓練與大型運算。

在手機、平板與單板電腦上，常使用 TensorFlow Lite，也就是現在的 LiteRT，或 PyTorch Mobile、ExecuTorch。

在微控制器與單晶片上，常使用 TensorFlow Lite for Microcontrollers，適合

低記憶體、低功耗的 TinyML 應用。